

Estudo sobre a interação de sensores de força resistivos e células de carga submetidos a restrições mecânicas

st Lucas Westfal
FGV EMap

Fundação Getúlio Vargas
Rio de Janeiro
lucaswestfal4@gmail.com

I. INTRODUÇÃO

Atualmente existem muitas linhas de pesquisa que aproveitam o advento de métodos de aprendizado de máquina para resolver problemas de alta complexidade. Em especial, é frequente usar cadeiras com dispositivos sensores acoplados para fazer inferências e previsões a respeito de hábitos posturais do usuário. Desses, vários trabalhos usam sensores do tipo FSR¹, como em [9], em que os autores usam 6 desses sensores para catalogar a posição do usuário com 97% de previsão usando *random forest*; o mesmo problema é visitado usando *deep learning* em [3]. Já em [5], usa-se malhas sensoras de distribuição de pressão² em uma cadeira para prever com 75,2% de eficácia se uma aula síncrona a distância consegue prender a atenção dos estudantes.

Sensores do tipo FSR têm natureza tátil, portando são usados quando existe contato direto com o objeto de estudo; isso faz com que esses dispositivos forneçam uma visão parcial do problema, já que qualquer parte do corpo do usuário que não esteja em contato com a cadeira torna-se invisível.

Existem também esforços voltados para o problema da categorização usando outros tipos de dispositivos eletrônicos para recolher dados. Usando sensores de distância³, [8] consegue tratar mais a fundo o problema, ao mapear as costas do usuário mesmo quando elas não encostam na cadeira.

Revisando a literatura, tornam-se evidentes duas coisas: em primeiro lugar, é de grande potencial usar vários tipos de sensores associados quando se ataca o problema de prever posturas; em segundo lugar, a literatura da área é intrinsecamente limitada, ao passo de que podemos encontrar muitos artigos que usam vários sensores associados, mas sem

garantias teóricas. Uma forma de resolver isso é adicionar estrutura aos dados e usar ferramentas mais sofisticadas para analisar o que os sensores nos dizem sobre o que estão tentando medir.

Nesse trabalho, se propõe um instrumento que associa medidas de sensores FSR e sensores do tipo célula de carga⁴. Ao contrário da maioria dos sensores usados em aplicações IOT⁵ ou no problema de previsão postural, células de carga conseguem capturar uma informação global da posição do corpo do usuário: a assimetridade da disposição do seu peso corporal; com os valores medidos dos sensores e com suas posições, podemos calcular a projeção do centro de massa do usuário no plano em que os sensores estão dispostos.

Na ausência de formas automatizadas de medição postural, essa ciência se desenvolveu em torno de observações de profissionais acerca de características posturais⁶. Não é exagero afirmar que estudos que caminhem na direção de unir métodos matemáticos, estatísticos e computacionais à literatura ortopédica⁷ têm grande potencial para o desenvolvimento da área.

¹Resistor sensível à força, um sensor tátil descrito em [2]

²Semelhante aos FSR, mas fornece dados em forma de uma matriz, e está sujeito a grande perda de precisão

³No caso, sensores infravermelhos explicados em [1]

⁴Também conhecidos como sensores de balança, tem funcionamento descrito em [7]

⁵IOT é o termo em inglês para *internet of things*, ou 'internet das coisas'

⁶Métodos assim podem ser vistos usados em [10]

⁷Como no estudo [6]

II. MÉTODOS

Para gerar os dados, foi usada uma bancada de testes de fabricação própria.



Fig. 1. Bancada durante coleta de dados

Onde os sensores de 1 a 4 são do tipo FSR e de 5 a 8 são do tipo célula de carga. Um diagrama em escala do circuito pode ser visto a seguir




Fig. 2. Diagrama do circuito

Trata-se de um objeto plano e de superfície macia que associa sensores de carga e sensores do tipo FSR, com o propósito de posicionar objetos sobre a bancada acionando vários sensores simultaneamente. A bancada e os experimentos possuem simetria espacial e isso será levado em conta nas análises.




Fig. 3. Posicionamento dos sensores, em milímetros

A precisão absoluta do posicionamento dos sensores é de ± 2 milímetros em suas coordenadas.

Os dados gerados se encontram em [11], juntamente do código que dá as medidas a serem usadas nos modelos. Para cada modelo, dados foram gerados em experimentos separados e com organização distinta, mas para todos fora usada uma mesma convenção de calibração dos sensores: medindo a bancada sem estímulo, obtemos a tara de cada sensor; a leitura dos sensores é aproximadamente linear em relação ao peso incidente, portanto as diferenças de leituras dos sensores em diferentes pesos, após tara, não precisam ser tratadas por serem acomodadas pelo modelo linear utilizado.

A. Modelo de regressão linear entre dados obtidos

O aparato matemático foi construído para responder se os dois conjuntos de sensores se complementam bem: se os dados dos FSR forem suficientes para prever a projeção do centro de massa do objeto que está em cima da bancada, fornecida pelas células de carga, teremos evidência de que não existe ganho significativo de informação ao associar os sensores; caso contrário, teremos evidência de que a associação é benéfica.

É usado um conjunto de dados em que um livro de capa dura foi disposto em cima dos sensores FSR e pressionado contra a bancada. O livro, em conjunto com a superfície macia da bancada, simula um objeto amorfo uniforme, como uma parte do corpo humano, visando aplicabilidade no caso dos estudos encontrados na revisão de literatura. Os dados são organizados conforme a tabela I

Onde x e y se são a abscissa e a ordenada da projeção ortogonal do centro de massa do objeto posto sobre a bancada no sistema coordenado ortogonal ilustrado na figura 3. Como o objetivo do experimento é estudar objetos amorfos, e pela simetria do experimento, supõe-se que x e y são

Tabela I
ESTRUTURA DOS DADOS ANALISADOS

Código do rótulo do rótulo	significado
intern_clock	Contagem de tempo desde início do experimento em ciclos de clock
1	Dados do sensor FSR da posição 1
2	Dados do sensor FSR da posição 2
3	Dados do sensor FSR da posição 3
4	Dados do sensor FSR da posição 4
x	Abscissa da estimativa de projeção de centro de massa do objeto medido sobre a mesa
y	Ordenada da estimativa de projeção de centro de massa do objeto medido sobre a mesa




Fig. 4. Posicionamento dos sensores, em milímetros

independentes.

Adotou-se então o modelo:

$$Y \sim \text{NORMAL}(\mu, \sigma)$$

$$\mu = \beta_0 + \beta_1 * S1 + \beta_2 * S2 + \beta_3 * S3 + \beta_4 * S4$$

Estimando separadamente x e y.

Os β_i são coeficientes do modelo, S1 a S4 são os valores dos sensores associados às colunas 1 a 4 dos dados e σ desvio padrão.

A abordagem escolhida foi Bayesiana e as distribuições a posteriori foram computadas usando MCMC. Os sensores FSR são relativamente acurados mas podem apresentar desvio de medição para valores maiores ou menores dos que devia medir, então a todos foi associada distribuição a priori normal de mesmos parâmetros.

Uma vantagem de se ter uma estrutura - geométrica - que gerou os dados se mostra nesse ponto: os intervalos de confiança das previsões tem interpretação imediata de uma região no espaço. Como a distribuição de Y dados os dados dos sensores é normal pelo modelo linear, então podemos associar uma "região de confiança" a cada previsão de $Y|\mu$, constituída pelo produto cartesiano entre o intervalo real $[\mu - \lambda\sigma, \mu + \lambda\sigma]$, $\lambda \in \mathbb{R}^+$, e \mathbb{R} . Fazendo isso em x e y, ficamos com as regiões da ilustradas na figura 4, onde a região pontilhada é a região

$$R = \{(x, y) \in [\mu_x - \lambda\sigma_x, \mu_x + \lambda\sigma_x] \times [\mu_y - \lambda\sigma_y, \mu_y + \lambda\sigma_y]\}$$

Se comporta como uma extensão da previsão pontual fornecida pela esperança de Y , com a confiança ajustada

por λ . Isso fornece uma métrica alternativa para validação cruzada, que resolve o problema de *outliers* frequentes - fruto de fenômenos eletrônicos - sem excluir dados, usando da interpretabilidade espacial dos coeficientes σ das regressões. Além desse método, foram analisados erros quadráticos e absolutos médios.

III. RESULTADOS

Antes de analisar os modelos, é necessário explorar os dados para verificar a sua qualidade. Para isso, elabora-se um teste: energizar o conjunto sensor sem mudar a tara, esperar 3 minutos e pressionar pontualmente a bancada; depois, pressionar a bancada de 2 em 2 minutos.




Fig. 5. Teste de funcionamento dos sensores

Pela figura 5 vemos que os sensores estão sendo acionados e que existe uma tendência clara para os dados quando não existe estímulo à bancada, com poucos *outliers*. Os sensores

6 e 8 apresentam medidas consistentes, enquanto o sensor 7 demorou para se estabilizar no início das médias e o sensor 5, após estímulo mecânico, por vezes não volta a medir o mesmo valor. O impacto dessas inconsistências será visível no resultado dos modelos.

A. Resultados do modelo

Para todas as computações foram usadas 1000 amostras e 4 cadeias.

Associa-se uma distribuição ao desvio padrão, onde sua média e características gerais devem respeitar os dados. Podemos ter uma estimativa usando os valores de calibração dos sensores, e escolher distribuições cuja média é essa estimativa. Esses valores são encontrados na tabela II ⁸.

Tabela II
DESVIOS PADRÃO DAS AMOSTRAS DE ABCISSA E ORDENADA COM BANCADA ESTATICA

	mean
x	0.654914
y	1.007197

1) *Priori do desvio padrão uniforme*: Uma opção de priori é uma uniforme que amostra apenas em positivos:

$$\sigma_x \sim U[0.654914 - 0.2, 0.654914 + 0.2]$$

$$\sigma_y \sim U[1.007197 - 0.2, 1.007197 + 0.2]$$

Ao atribuir priori uniforme limitando a variância, obtemos

Tabela III
DISTRIBUIÇÃO A POSTERIORI DOS COEFICIENTES DA REGRESSÃO EM X

	mean	sd	mcse_mean	mcse_sd
β_0	0.078	0.936	0.466	0.357
β_1	-0.438	0.816	0.406	0.311
β_2	0.009	1.375	0.685	0.524
β_3	0.91	1.126	0.561	0.429
β_4	0.381	1.364	0.679	0.52
σ	0.855	0.0	0.0	0.0

O modelo rejeitou a priori e retornou desvio padrão zero, isso é, considerando constante. Além disso, as amostragens convergiram para valores bastante distintos entre si gerando inconclusão, como fica claro com a figura 6.

2) *Priori do desvio padrão gama*: Para usarmos a mesma média e variância da priori com desvio padrão uniforme, precisamos dos parâmetros de forma e taxa:

⁸O cálculo pode ser encontrado no notebook corrigindo_dados_livro presente no repositório [11]

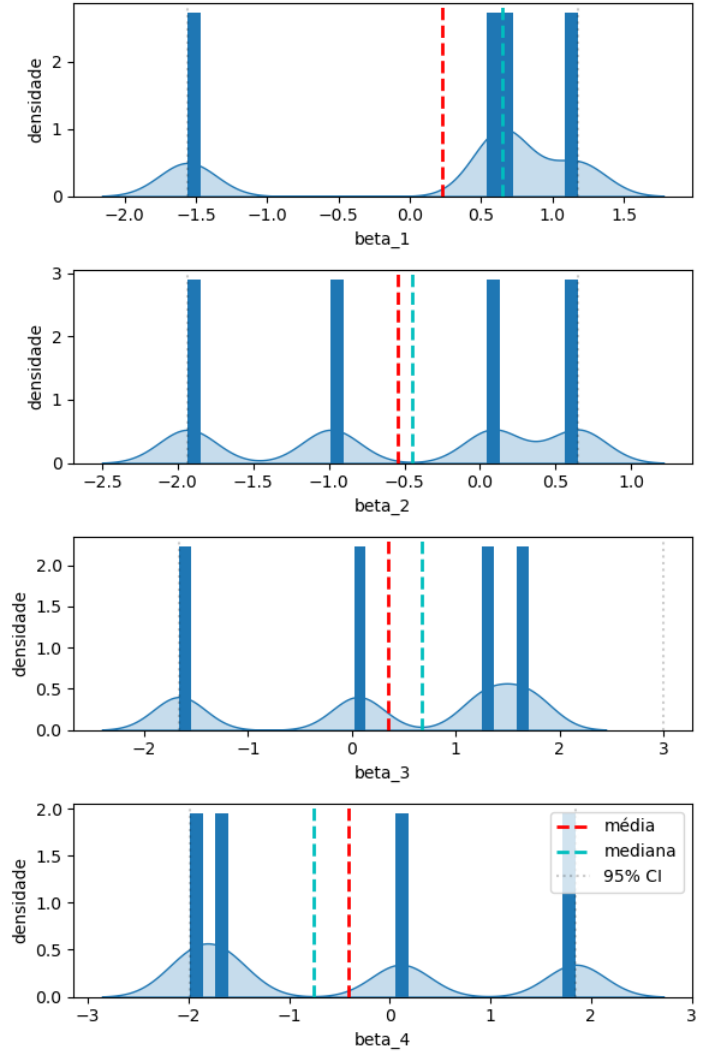


Fig. 6. Posteriori dos parâmetros do modelo x

$$\sigma_x \sim \text{gamma}(32, 168426055; 49, 11855)$$

$$\sigma_y \sim \text{gamma}(76, 083434761; 75, 539775)$$

Ao atribuir priori gama limitando a variância, obtemos

Tabela IV
DISTRIBUIÇÃO A POSTERIORI DOS COEFICIENTES DA ABCISSA

	mean	sd	mcse_mean	mcse_sd
β_0	-16.873	8.505	0.124	0.093
β_1	-59.402	32.168	0.484	0.391
β_2	37.728	28.725	0.422	0.329
β_3	-2.424	99.698	1.385	1.761
β_4	-0.795	102.058	1.493	1.559
σ	208.799	1.193	0.017	0.012

Por simetria, espera-se que os erros quadráticos sejam semelhantes. A disparidade entre os coeficientes dos sensores 1 e 2 com os coeficientes dos sensores 3 e 4 mostra que a simetria do experimento não é refletida nos dados, indicando falha de desenho experimental, execussão, mecânica ou eletrônica. Considere os percentis da figura 7; podemos perceber que os sensores 3 e 4 em nada contribuem com o modelo: tem média muito próxima de zero e são aproximadamente simétricos. Não se pode decidir se tem influência negativa ou positiva e portanto não são bons preditores.




Fig. 7. Posteriori dos parâmetros do modelo x

Quanto ao σ , foi possível estabelecer um intervalo de confiança de 95% entre os pontos 206,86 e 210,76. A abscissa varia entre -90 e 90. Então, se for posto um objeto no centro do eixo coordenado, mal podemos assegurar que seu centro de massa está sobre a bancada.

Analisando os preditores da ordenada na tabela V, tendência de comportamento dos sensores segue a mesma, mas a estimativa de σ mudou consideravelmente. Foi possível estabelecer um intervalo de confiança de 95% entre os pontos 45,91 e 47,63. A ordenada varia entre -120 e 120, então é

Tabela V
DISTRIBUIÇÃO A POSTERIORI DOS COEFICIENTES DA ORDENADA

	mean	sd	mcse_mean	mcse_sd
β_0	12.333	1.837	0.026	0.018
β_1	17.354	7.385	0.104	0.078
β_2	4.865	6.628	0.095	0.087
β_3	-3.411	99.304	1.367	1.599
β_4	1.379	101.632	1.354	1.706
σ	46.768	0.516	0.007	0.005

possível indicar com relativa certeza se um objeto posto sobre a bancada tem seu centro de massa projetado no semiplano superior ou inferior do sistema coordenado.




Fig. 8. Posteriori dos parâmetros do modelo y

B. Validação

Para validação do modelo, foi empregado validação cruzada com separação aleatorizada de 30% dos dados para teste, e as métricas adotadas foram de avaliação de erro quadrático médio, erro absoluto médio e contagem de estimativas do vetor $[x, y]$ que estão dentro da região de confiança do modelo dado coeficiente λ .

Na tabela VI encontramos erros excessivamente grandes ára x e moderados para y: em média as previsões erraram

Tabela VI
SOMA DOS ERROS QUADRÁTICOS

Alvo	Erro quadrático médio	Erro absoluto médio
x	1889850.72	187.53
y	10060.95	31.63

apenas em 30mm.

Tabela VII
PROPORÇÃO ENTRE PONTOS DENTRO E FORA DA REGIÃO DE CONFIANÇA

λ	Proporção
0.1	0.0047
0.2	0.0616
0.5	0.3933
1	0.8293
1.5	0.8957
2	0.9241

Pela tabela VII verificamos que poucos pontos foram muito bem preditos e que uma quantidade grande de pontos se encontra muito longe da estimativa.

IV. CONCLUSÃO

Conclui-se que o conjunto de sensores FSR não são capazes de prever com eficiência os dados gerados pelas células de carga na atual configuração do experimento, muito embora na tabela VI houve indicação de que ao refazer o experimento corrigindo os métodos de coleta de dados pode-se chegar a conclusões positivas.

A. Dos dados

A começar, duas das células de carga não se mostraram confiáveis, e isso se refletiu nos dados quando o eixo que apresentou menor variância no modelo linear: os sensores de carga 5 e 7 estão opostos pelo eixo da direção de x e, portanto, geram dados significativos para estimar o valor de y.

Foram gerados mais dados que não puderam ser analisados. Esses dados são de um segundo experimento que aumenta as restrições geométricas a fim de transformar os dados 4-dimensionais em pontos em um plano, para então poder usar ferramentas tradicionais de regressão linear; entretanto isso não foi possível, por falta de tempo e pelos problemas supracitados dos dados. Pretendo movimentar recursos para viabilizar análises mais concretas e conclusivas.

B. Dos modelos

1) *Regressão multivariada*: Seria produtivo modelar a coordenada da projeção do centro de massa, do modelo estudado, como tendo distribuição multivariada

$$\tilde{Y} \sim MVN_2(\mu, \Sigma)$$

Em que

$$\begin{aligned} \mu &= [\mu_1, \mu_2]^T \\ \mu_i &= \beta_{0,i} + \beta_{0,i}S1 + \beta_{0,i}S2 + \beta_{0,i}S3 + \beta_{0,i}S4 \end{aligned}$$

E em que Σ é matriz de duas linhas e duas colunas. A modelagem presente neste trabalho assume que as coordenadas de \tilde{Y} são independentes, isso é, que Σ tem diagonal secundária nula. Fazer uma regressão como descrita testaria essa hipótese.

2) *Prioris adotadas*: As distribuições a priori adotadas foram escolhidas por critério teórico e de verossimilhança com os dados, mas testar outras opções seria interessante a fim de tentar achar modelos que façam previsões melhores. Aos β cabe perfeitamente as distribuições normais, mas associar outra distribuição pode ser útil.

O problema enfrentado com a priori uniforme para o desvio padrão poderia ser evitado usando uma distribuição mais bem comportada e semelhante na escala, como uma beta. No entanto isso seria artificialmente restringir uma variância que sabidamente será alta; além disso, o algoritmo seguiu assumindo que σ era constante e o resultado inconclusivo apresentado se seguiu.

3) *Coefficientes*: Em razão do tempo, não foi possível experimentar com coeficientes de diferentes potências. Tendo em vista que os sensores todos tem comportamento aproximadamente linear, espera-se que fazê-lo não traga muita diferença para a capacidade preditiva; isso entretanto só pode ser sustentado uma vez que posto em prova pelos dados.

C. Da bancada

As escolhas de projeto da bancada tiveram grande impacto na qualidade dos dados.

A começar, os sensores FSR escolhidos foram os menores disponíveis, para poder aproximar sua leitura de um sensor pontual; futuramente convém experimentar com sensores de tamanho maior - e com mais confiabilidade - para comparar os resultados.

Um grande problema que não pôde contornado foi o da faixa de trabalho das células de carga. Cada uma das quatro é feita para suportar até 40kg, contudo a bancada tem peso desprezível e o peso usado para pressionar a bancada variou entre 10kg e 20kg. Fabricar uma bancada mais pesada faria com que os sensores se deformassem mais e isso aumentaria a confiabilidade dos dados, uma vez que as células de carga foram feitas para trabalhar sob carga constante.

Também é necessário avaliar a razão de flutuações de dados que acometeram não só as células de carga mas também os FSR. Não fui capaz de identificar o motivo, mas para continuar estudando o tema é essencial garantir que essa fonte de incerteza não atrapalhe novamente as medições.

REFERÊNCIAS

- [1] ALL DATASHEET.
- [2] Digi-Key electronics.
- [3] Cho et al. Sitting posture prediction and correction system using arduino-based chair and deep learning model. *IEEE*, 2020.
- [4] Gelman et al. *Regression and Other Stories*. Cambridge University Press, 2022.
- [5] Nomura et al. Estimation of student's engagement using a smart chair. *ACM*, 2018.
- [6] Santos et al. Presença de assimetrias posturais e dores musculoesqueléticas em membros superiores de indivíduos adultos com excesso de peso. *Centro científico conhecer*, 2018.
- [7] Gotronic.
- [8] H. Jeong and W. Park. Developing and evaluating a mixed sensor smart chair system for real-time posture classification: Combining pressure and distance sensors. *IEEE*, 2020.
- [9] F. Lee and C. Lee. User activity recognition based on smart chair with pressure sensors. *IEEE*, 2018.
- [10] Isis Juliene Rodrigues Leite Navarro. Identificação da escoliose a partir de parâmetros da superfície corporal. *UFRGS*, 2018.
- [11] L. Westfal. sensor_analysys. https://github.com/LucasWestfal/sensor_analysys, 2023.